# 같은 커피 취향을 다르게 말하면

# AI 의 원두 추천도 달라질까?

문장 표현 3 종 × 10 회 반복 실험

과제 10  AI 와 함께 쓰는 첫 논문 — 가설에서 결론까지

작성자: 변준혁

작성일: 2026 년 11 월 1 일

## 초록

AI 에게 말하는 방식(구체적 서술, 짧은 키워드, 비유적 표현)에 따라 추천이 얼마나 달라지는지 궁금해서, 커피 원두 추천으로 확인했다. 취향(강한 산미, 꽃향, 시트러스 계열 과일향, 긴 여운, 약한 쓴맛)은 그대로 두고 문장만 세 가지(A 자세한 서술, B 짧은 키워드, C 비유)로 바꿔, 문장마다 10 번씩 모두 30 번 Claude Sonnet 5.5 에 보내고 추천된 원두 5 개씩을 기록했다. 두 응답에서 같은 원두가 몇 개인지(0~5 개) 세어, 같은 문장끼리 비교한 값(기준선)과 문장이 다른 응답끼리 비교한 값을 견주었고, 미리 정한 기준(기준선보다 0.5 개 이상 낮으면 "달라졌다")으로 판정했다. 문장이 다른 응답끼리는 평균 3.85~4.02 개가 같았고 기준선(3.96~4.16 개)보다 0.04~0.14 개 낮았을 뿐이어서, 세 쌍(A-B, A-C, B-C) 모두 "비슷하다"였다. 따라서 이 실험에서 가설은 지지되었다. 다만 세 문장이 같은 취향 5 요소를 모두 담았고 AI 가 어떤 문장에도 에티오피아 예가체프와 케냐를 빠짐없이 추천해서 차이가 날 여지가 작았을 수 있으며, 취향을 말로 표현하기 어려운 사람의 경우는 확인하지 못했다.



**핵심어:** 프롬프트 표현, 추천의 일관성, 원두 추천, 반복 실험


# 1. 서론

## 1.1 관심 분야와 문제의식

관심 분야는 AI, 커피, 음악이고, 그중 AI 와 커피가 겹치는 지점에서 주제를 찾았다. AI 에게 같은 내용을 말하는 방식은 사람마다 다르다. 자세히 풀어 쓰는 사람(구체적 서술), 키워드만 던지는 사람(짧은 키워드), 비유로 말하는 사람(비유적 표현)이 있다. 이렇게 말하는 방식에 따라 AI 의 답이 얼마나 달라지는지 궁금했다. 특징이 분명히 담겨 있다면 방식이 달라도 답이 거의 비슷할 것이라고 예상했고, 커피 원두 추천을 실험 대상으로 삼아 확인해 보기로 했다.

## 1.2 검토한 후보 주제와 접은 이유

AI 에게 관심 분야를 말하고 확인해 볼 만한 질문 10 개를 받았다. 처음 받은 10 개는 분야를 하나씩만 넣은 느낌이 강해서 버리고, 분야가 섞이도록 다시 받았다. 다시 받은 10 개 중 끌리는 4 개(3, 4, 8, 10 번)를 직접 골랐고, 그중 10 번을 최종 주제로 정했다.

| # | 섞인 분야 | 질문 |
|---|---|---|
| 1 | AI+커피 | AI 에게 존재하지 않는 가상의 원두 이름을 물으면, 실제 원두를 물을 때보다 맛 설명을 지어내는 비율이 높은가 |
| 2 | AI+커피 | 같은 원두 정보로 추출 레시피(물 온도, 커피:물 비율)를 10 번 물으면 값이 얼마나 흔들리고, 공개된 권장 범위 안에 드는 비율은 얼마인가 |
| 3 | AI+커피 | 질문을 한국어로 할 때와 영어로 할 때 추천 원두가 달라지는가 |
| 4 | AI+커피 | 사용자가 "커피 초보"라고 밝히면 추천하는 원두나 추출 방식의 난이도가 달라지는가 |
| 5 | AI+음악 | "비 오는 날 카페" 같은 같은 분위기를 표현만 바꿔 말하면 추천곡이 얼마나 겹치는가 |
| 6 | AI+음악 | AI 가 추천한 곡 목록 중 실제로 존재하지 않는 곡이나 잘못된 아티스트의 비율은 얼마인가 |
| 7 | 커피+음악 | 커피 로스팅 단계(라이트/미디엄/다크)가 어울리는 음악의 템포나 장르에 영향을 주는가 |
| 8 | AI+커피+음악 | 커피 맛 설명(산미, 바디감 등)을 주고 어울리는 음악을 추천받을 때, 맛 설명 종류에 따라 추천 장르가 체계적으로 달라지는가 |
| 9 | AI+음악+커피 | 같은 "카페에서 틀 음악" 요청에 시간대(아침/저녁)를 바꿔 말하면 추천곡의 분위기와 함께 추천하는 음료도 달라지는가 |

| # | 섞인 분야 | 질문 |
|---|---|---|
| 10 | AI+커피 | AI 에게 같은 취향을 말하고 원두를 추천받을 때 질문 표현에 따라 추천이 달라지는가 |

*표 1. 검토한 후보 주제 10 개 (최종 선택: 10 번)*

직접 고른 4 개 가운데 최종으로 정한 10 번을 뺀 3 개를 접었다. 접은 주제와 이유는 아래와 같다.

| 접은 주제 | 접은 이유 |
|---|---|
| 3 번 한국어/영어 | 10 번과 구조가 같고("질문 표현이 추천을 바꾸는가"), 언어 비교는 번역 차이가 섞여서 어디서 달라졌는지 가르기 어렵다. 10 번이 표현 조건을 더 자유롭게 설계할 수 있다. |
| 4 번 "커피 초보" | 추천의 난이도를 숫자로 재는 기준을 따로 만들어야 해서 측정이 주관적이 될 수 있다. 10 번은 겹침 정도로 바로 잰다. |
| 8 번 맛 설명 → 음악 장르 | "장르가 체계적으로 달라진다"의 판단 기준이 흐릿하고, 커피와 음악 두 분야가 섞여 변수가 많다. |

*표 2. 접은 주제와 이유*

## 1.3 선행 연구

선행 연구는 검색으로 후보를 찾고 arXiv 원문 페이지에서 제목과 저자를 직접 확인한 4 편을 썼다. 요약은 초록 수준에서 읽은 것이다.

| 문헌 | 이 연구의 어느 부분과 이어지는가 | 실험·데이터 검증 |
|---|---|---|
| [1] | 의미를 유지한 문장 형식 변화에도 모델 성능이 크게 달라질 수 있다고 보고했다. 이 연구의 가설과 반대 방향의 선행 결과이며, "표현을 바꾼다"는 독립 변수의 근거가 된다. | 예. 여러 모델로 형식 변화를 실험 |
| [2] | 추천 과제에서 입력을 살짝 바꾸면 추천 순위의 유사도가 낮게 나왔다. 종속 변수가 "추천 결과의 겹침"이라는 점의 선행 사례이며 역시 반대 방향이다. 다만 이 연구의 변화는 프롬프트에 공백이나 무작위 요소를 더하는 것이고, 의미를 유지한 문장 변화는 아니다. | 예. MovieLens 와 GPT-3.5 로 실험 |
| [3] | 같은 프롬프트를 반복해도 결과가 달라지고, 온도를 0 으로 낮춰도 완전히 같아지지 않는다. "같은 문장 반복"을 기준선으로 두는 이유가 된다. | 예. 829 개 문제로 실험 |
| [4] | 온도 0 등 결정적 설정으로 10 회 반복해도 결과가 매번 같지 않았다. 반복 횟수를 10 회로 정한 점과 기준선의 필요성을 뒷받침한다. | 예. 5 개 모델, 8 개 과제, 각 10 회 반복 |

*표 3. 참고문헌별 연결 한 줄*

**이미 알려진 사실:** 의미가 같은 프롬프트 변화에도 LLM 의 결과가 달라질 수 있고[1], 추천 과제에서도 입력의 작은 변화가 추천 결과를 바꿀 수 있으며[2], 같은 입력을 반복해도 결과는 매번 조금씩 다르다[3][4].

**이 연구에서 새로 확인하려는 것:** 같은 커피 취향을 서로 다른 문장(구체적 서술, 키워드, 비유)으로 말했을 때 추천된 원두 목록이 얼마나 겹치는지를 같은 문장 반복의 겹침과 비교해서 본다. [1][2]는 표현을 바꾸면 결과가 달라진다고 보고했으므로 이 연구의 가설은 선행 연구와 다른 방향이다. 결과가 선행 연구와 같게 나오면(겹침이 낮으면) 가설은 기각되며 그것도 의미 있는 결과다.

**목록에서 뺀 문헌:** Li, Zhao, Zhao, Wu, & He (2024)의 GANPrompt(arXiv:2408.09671)는 실제로 존재하는 논문이지만, 추천에서 LLM 이 문구 변화에 민감하다는 점을 이미 알려진 전제로 두고 개선 방법을 제안한 연구다. 민감성 자체를 새로 측정한 연구가 아니어서 근거로는 약하다고 판단해 뺐다.

**출처를 확인한 방법:** 세 주제(프롬프트 표현 민감성, LLM 기반 추천의 견고성, 같은 입력의 반복 결과 변동)로 검색해 후보 5 편을 찾고, 각 후보의 arXiv 원문 페이지를 열어 제목, 저자, 초록을 확인했다. [1]~[4]는 작성자가 직접 arXiv 페이지에서 제목과 저자가 참고문헌 표기와 일치하는지 확인했고, [2]는 제출일(2024 년 11 월 18 일)

도 직접 확인했다. 표 3 에 적은 숫자(MovieLens 와 GPT-3.5, 829 개 문제, 5 개 모델·8 개 과제·10 회 반복)는 2026 년 11 월 1 일에 arXiv 초록에서 다시 확인했다. [2]는 학회 게재 여부를 확인하지 못해 arXiv preprint 로만 적었다.

### 1.4 가설

> **같은 커피 취향을 서로 다른 문장으로 표현해 AI 에게 원두를 추천받아도, 표현이 달라진 것만으로는 추천된 원두 목록이 크게 달라지지 않는다.**

영향을 주는 것은 취향을 말하는 문장 표현이고, 영향을 받는 것은 추천된 원두 목록이다. 가설은 이 영향이 작다는 것이다. 가설이 틀렸다면 서로 다른 표현 사이의 겹침이 같은 문장을 반복한 사이의 겹침보다 뚜렷하게 낮게 나온다. 그 경우 어느 표현 쌍에서 갈라지는지가 새로운 분석 대상이 된다.

가설을 다듬은 과정은 다음과 같다. AI 가 처음 제시한 가설 초안은 "표현이 달라질수록 겹침이 줄어든다"였다. 작성자는 "표현이 조금 달라도 추천 원두 목록은 비슷할 것"이라고 예상해서 방향을 반대로 바꿨다. AI 는 "비슷하다"를 판단하려면 같은 문장 반복의 겹침을 기준선으로 두어야 한다고 제안했고, 이를 설계에 반영했다. 커피 취향은 작성자가 직접 정했다. 이 가설을 최종으로 고른 이유는 (1) 처음부터 관심이 있었고 취향을 직접 정할 수 있으며, (2) 겹침으로 바로 숫자로 잴 수 있고, (3) 같은 문장 반복을 기준선으로 두면 가설이 맞아도 틀려도 의미 있는 결론이 되며, (4) 요청 30 회로 하루~이틀 안에 별도 장비 없이 데이터를 모을 수 있기 때문이다.

## 2. 방법

### 2.1 실험 설계

| 항목 | 내용 |
|---|---|
| 실험 방법 | AI 에게 같은 요청을 문장 표현만 바꿔 여러 번 보내고, 추천된 원두 목록을 기록한다 |
| 사용하는 AI | Claude Sonnet 5.5, 모델 이름 옆 설정 "중간" (비공개 대화 화면에서 확인) |
| 바꾸는 조건 | 취향을 말하는 문장 표현 3 종 (A 구체적 서술, B 짧은 키워드, C 비유적 표현) |
| 반복 횟수 | 문장마다 10 회 |
| 표본 수 | 3 종 × 10 회 = 30 회 요청, 응답당 원두 5 개이므로 원자료 150 건 |
| 측정한 값 | 요청마다 추천된 원두 5 개 (생산국, 세부 지역, 품종, 가공 방식). 응답 원문 전체와 화면 캡처도 저장 |
| 수집 기간 | 2026 년 10 월 30 일(요청 1~3), 11 월 1 일(요청 4~30) |

*표 4. 실험 설계*

**문장 3 종 (실행 중 바꾸지 않음)**

| 표현 | 문장 |
|---|---|
| A. 구체적 서술 | 저는 산미가 강하고, 꽃향기와 시트러스 계열 과일향이 나며, 마시고 난 뒤 여운이 길고, 쓴맛이 약한 커피를 좋아합니다. 이런 취향에 맞는 원두를 5 가지 추천해 주세요. |
| B. 짧은 키워드 | 강한 산미, 꽃향, 시트러스, 긴 여운, 약한 쓴맛. 이 취향에 맞는 원두를 5 가지 추천해 주세요. |
| C. 비유적 표현 | 오렌지나 자몽처럼 새콤하게 톡 쏘고, 꽃잎에서 나는 향이 나며, 마신 뒤에도 그 향이 입안에 오래 남고, 씁쓸함은 거의 없는 커피를 좋아해요. 이런 취향에 맞는 원두를 5 가지 추천해 주세요. |

*표 5. 사용한 문장 3 종*

### 2.2 바꾼 조건과 고정한 조건

| 구분 | 조건 | 값 |
|---|---|---|
| 바꾼 조건 | 문장 표현 | A, B, C |
| 고정 | 취향의 5 개 요소 | 강한 산미, 꽃향, 시트러스 계열 과일향, 긴 여운, 약한 쓴맛 |
| 고정 | 요청 문장, 추천 개수 | "원두를 5 가지 추천해 주세요", 5 개 |
| 고정 | 대화 | 매 요청마다 새 대화를 열고 대화 하나에 요청 하나만 보낸다. 추가 질문과 다시 생성하기는 쓰지 않았다 |
| 고정 | 기억 기능 | 평소 쓰는 계정이라 기억 기능은 끄지 않고, 30 회 모두 비공개(incognito) 대화에서 보냈다. Claude 고객센터 안내("Use incognito chats")에 비공개 대화는 기존 기억을 쓰지 않는다고 적혀 있다 |
| 고정 | 추가 기능 | 리서치, 커넥터, Skills, 플러그인, 파일 첨부는 쓰지 않았다. 프로젝트 밖의 일반 대화에서 보냈다 |
| 고정(끌 수 없음) | 웹 검색 | 화면에서 끄는 항목이 없었다. 요청마다 웹 검색 표시가 있었는지 기록했고, 30 회 모두 표시가 없었다 |
| 고정 | 모델, 계정, PC | Claude Sonnet 5.5 "중간", 같은 계정, 같은 PC(PC1) |

*표 6. 바꾼 조건과 고정한 조건*

시간에 따른 영향이 한 문장에만 쏠리지 않도록 3 문장을 돌려가며 보냈다. 라운드 1, 4, 7, 10 은 A→B→C, 라운드 2, 5, 8 은 B→C→A, 라운드 3, 6, 9 는 C→A→B 순서이고, 라운드 r 은 요청 3r−2~3r 이다. 본 실험 전에 문장 A 로 2 회 시험 삼아 보내 기록 방식을 점검했으며, 시험 실행 응답은 30 건에 포함하지 않고 따로 보관했다.

## 2.3 같은 원두를 판단하는 규칙

응답에 적힌 원두 이름은 "에티오피아 예가체프(워시드, G1)", "케냐 AA", "파나마 게이샤"처럼 나라, 지역, 품종, 가공 방식, 등급이 제각각 섞여 있다. 그래서 원두마다 응답의 제목 줄(번호가 붙은 줄)에 적힌 내용만 보고 생산국, 세부 지역, 품종, 가공 방식 네 칸으로 정리했고, 아래 규칙으로 두 원두가 같은지 판단했다. 농장 이름(게이샤 빌리지)은 세부 지역 칸에 넣었다.

1. 두 원두의 네 칸 가운데 두 쪽 모두에 적힌 칸만 비교한다. 한쪽이라도 비어 있으면 그 칸은 건너뛴다.
2. 한 칸에 값이 둘 이상이면("구지 / 시다모", "르완다 또는 부룬디") 하나라도 상대와 겹치면 그 칸은 같다.
3. 비교한 칸이 모두 같으면 같은 원두이고, 하나라도 다르면 다른 원두다.
4. 예외: 한쪽에만 품종이 적혀 있으면 다른 원두로 본다. (건너뛰기 규칙만 쓰면 에티오피아 게이샤와 에티오피아 예가체프가 나라만 비교해서 같다고 나오기 때문이다.)
5. 등급(AA, G1), 로스팅 정도, 표기 언어, 표기 차이(게샤와 게이샤, 시다마와 시다모)는 무시한다.
6. 두 응답의 겹침은 일대일로 센다. 한 원두는 상대 응답의 원두 하나와만 짝이 되고, 짝이 가장 많아지게 짝을 지어 센다. 겹침은 0 에서 5 사이의 정수다.

보조 규칙으로, 정리한 이름(네 칸을 이은 값, 빈칸 포함)이 완전히 같을 때만 같은 원두로 보는 계산을 함께 했다. 같은 원두인데 한쪽이 지역을 적고 다른 쪽이 적지 않은 경우를 모두 다른 원두로 세기 때문에 겹침이 낮게 나오지만, 주 규칙의 결론이 이 판단 규칙에만 좌우되는지 확인하는 용도다.

## 2.4 "비슷하다"를 판단하는 규칙 (데이터 수집 전에 확정)

1. 기준선: 같은 문장으로 보낸 10 개 응답에서 가능한 모든 쌍(문장마다 45 쌍)의 겹침을 평균낸다. A, B, C 각각 구한다.
2. 표현 간 겹침: A 와 B(100 쌍), A 와 C(100 쌍), B 와 C(100 쌍)의 겹침을 쌍마다 평균낸다.

3. 판단: 표현 간 평균 겹침이 두 문장의 기준선 평균보다 0.5 개 이상 낮으면 "달라졌다", 덜 낮으면 "비슷하다"로 한다. A-B, A-C, B-C 를 각각 판단한다.
4. 가설 판정: 세 쌍이 모두 "비슷하다"이면 가설을 지지하고, 하나라도 "달라졌다"이면 어느 쌍에서 달라졌는지를 결과로 적는다. 기준(0.5 개)은 데이터를 모으기 전에 정했고 결과를 보고 바꾸지 않았다.

처음 가설 문서에서는 겹침을 "겹친 수 ÷ 5"로 적었다. 이 논문에서는 같은 정보를 개수(0~5)로 적는다. 개수를 5 로 나누면 처음 정의와 같고, 0.5 개는 0.1 에 해당한다.

### 2.5 설계 변경 기록

| 시점 | 바꾼 것 | 이유 |
|---|---|---|
| 시험 실행 2 회 후, 본 데이터 수집 전 (2026-10-30) | "한 항목에 지역이나 나라가 둘 이상이면 하나라도 같을 때 같은 것으로 본다"는 규칙을 추가했고, 정리표에 비고 열을 두었다. | 시험 응답에 "구지 / 시다모", "르완다 또는 부룬디"처럼 한 항목에 둘 이상이 적힌 경우가 있었는데 기존 규칙에 이를 다루는 내용이 없었다. AI 가 둘을 적는 순서에 결과가 좌우되지 않도록 작성자가 "하나라도 같으면 같음"을 선택했다. |
| 30 회 수집 후, 겹침 계산 전 (2026-11-01) | 같은 원두 판단 규칙을 확정했다. 비교 칸을 세 칸(생산국, 세부 지역, 가공 방식)에서 품종을 더한 네 칸으로 늘렸고, 두 쪽 모두에 적힌 칸만 비교하는 규칙, 한쪽에만 품종이 있으면 다른 원두로 보는 예외, 일대일 세기, 이름이 완전히 같을 때만 같다고 보는 보조 규칙을 넣었다. 정리표에 품종과 사용 PC 열을 더했다. | 본 데이터에서 응답 제목에 등급(AA, G1), 품종(게이샤), 농장 이름(게이샤 빌리지)이 지역과 섞여 적혀 세 칸으로는 판단이 맞지 않았다. 확정 전 점검에서 건너뛰기 규칙만 쓰면 에티오피아 게이샤와 예가체프가 같다고 나오는 문제가 발견되어 예외를 넣었다. 이 규칙은 30 회를 모두 모은 뒤에 정했지만, 겹침 숫자는 규칙 확정 전에는 계산하지 않았다. |

*표 7. 설계 변경 기록*

"비슷하다"의 기준(0.5 개)과 문장 3 종은 수집 전에 확정한 뒤 바꾸지 않았다.

## 3. 결과

30 개 응답(A, B, C 각 10 개)에서 원두 150 개를 모았다. 아래 숫자는 모두 원자료(data.csv)에서 scripts/analyze.py 가 계산한 값이다.

### 3.1 주 규칙 결과

| 비교 | 쌍 수 | 문장이 다른 응답끼리 평균 | 같은 문장끼리(기준선) 평균 | 기준선보다 낮은 정도 / 판정 |
|---|---|---|---|---|
| A-B | 100 | 3.96 | 4.00 | 0.04 / 비슷하다 |
| A-C | 100 | 4.02 | 4.16 | 0.14 / 비슷하다 |
| B-C | 100 | 3.85 | 3.96 | 0.11 / 비슷하다 |

*표 8. 같은 원두 개수의 평균(최대 5). 기준선은 두 문장의 같은 문장끼리 평균의 평균. 같은 문장끼리 평균은 A 4.20, B 3.80, C 4.11 (각 45 쌍)*

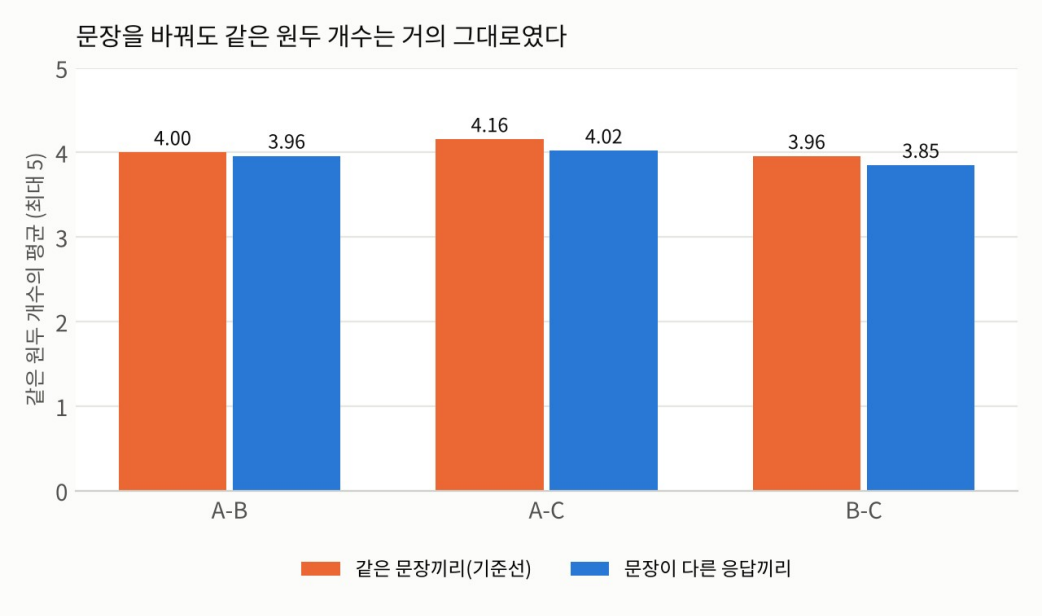



*그림 1. 기준선과 표현 간 겹침의 평균 (주 규칙)*

## 3.2 겹침 개수별 쌍 수 (주 규칙)

| 비교 | 0 개 | 1 개 | 2 개 | 3 개 | 4 개 | 5 개 | 합계 |
|---|---|---|---|---|---|---|---|
| A 끼리 | 0 | 0 | 0 | 4 | 28 | 13 | 45 |
| B 끼리 | 0 | 0 | 2 | 15 | 18 | 10 | 45 |
| C 끼리 | 0 | 0 | 0 | 5 | 30 | 10 | 45 |
| A-B | 0 | 0 | 1 | 27 | 47 | 25 | 100 |
| A-C | 0 | 0 | 0 | 16 | 66 | 18 | 100 |
| B-C | 0 | 0 | 7 | 15 | 64 | 14 | 100 |

*표 9. 응답 쌍을 같은 원두 개수별로 센 값. 겹침이 1 개 이하인 쌍은 없었다*

## 3.3 보조 규칙 결과 (이름이 완전히 같을 때만 같은 원두)

| 비교 | 쌍 수 | 문장이 다른 응답끼리 평균 | 같은 문장끼리(기준선) 평균 | 기준선보다 낮은 정도 / 판정 |
|---|---|---|---|---|
| A-B | 100 | 1.80 | 1.86 | 0.06 / 비슷하다 |
| A-C | 100 | 1.44 | 1.84 | 0.40 / 비슷하다 |
| B-C | 100 | 1.61 | 1.66 | 0.05 / 비슷하다 |

*표 10. 보조 규칙. 같은 문장끼리 평균은 A 2.04, B 1.67, C 1.64*

## 3.4 어떤 원두가 추천되었는가

| 원두 묶음 | A (10 개 응답 중) | B (10 개 응답 중) | C (10 개 응답 중) |
|---|---|---|---|
| 에티오피아 예가체프 | 10 | 10 | 10 |
| 케냐 | 10 | 10 | 10 |
| 파나마 게이샤 | 10 | 10 | 8 |

| 원두 묶음 | A (10 개 응답 중) | B (10 개 응답 중) | C (10 개 응답 중) |
|---|---|---|---|
| 에티오피아 구지·시다모 | 6 | 8 | 10 |
| 르완다·부룬디 | 9 | 8 | 5 |
| 에티오피아 게이샤 계열 | 6 | 6 | 6 |
| 콜롬비아 | 6 | 3 | 6 |

*표 11. 응답 10 개 중 그 원두 묶음이 한 번 이상 들어 있던 응답의 수 (설명용 집계이며 판정에는 쓰지 않음)*

### 3.5 가설대로 나온 부분과 다르게 나온 부분

**가설대로 나온 부분.** 세 쌍 모두 문장이 다른 응답끼리의 평균이 같은 문장끼리의 기준선보다 0.04~0.14 개 낮았을 뿐이며 사전에 정한 기준(0.5 개)에 한참 못 미쳤다(표 8). 보조 규칙에서도 세 쌍 모두 "비슷하다"였다(표 10). 예를 들어 요청 16(문장 C)과 요청 17(문장 A)은 5 개 중 4 개가 같았다.

**가설의 기대와 다르거나 주의가 필요한 부분.** 결과가 가설과 정반대로 나온 곳은 없었지만, 아래는 그대로 적는다.

- 같은 문장을 반복해도 응답이 완전히 같지는 않았다. 같은 문장끼리의 평균은 3.80~4.20 개이고, 5 개가 모두 같았던 쌍은 A 13 쌍(45 쌍 중), B 10 쌍, C 10 쌍이었다(표 9).
- 짧은 키워드 문장(B)의 기준선이 3.80 으로 A 4.20, C 4.11 보다 낮았다. 겹침이 2 개로 가장 낮았던 쌍은 B 가 들어간 쌍에서만 나왔다(B 끼리 2 쌍, A-B 1 쌍, B-C 7 쌍, 표 9).
- 보조 규칙에서 A-C 는 0.40 개 낮아 기준 0.5 개에 가장 가까웠다(표 10). 이 계산은 같은 원두를 지역 표기 유무로 다르게 세기 때문에 기준선 자체가 1.64~2.04 개로 낮다.
- 추천된 원두 150 개 중 134 개(89%)가 같은 다섯 묶음(예가체프, 케냐, 파나마 게이샤, 구지·시다모, 르완다·부룬디)에 들어갔고, 나머지 16 개가 그 밖의 원두였다. 에티오피아 예가체프와 케냐는 30 개 응답 모두에 들어 있었다(표 11).
- 요청 3 개(13, 15, 20)의 응답에 질문에 없던 "대구"라는 지역 언급이 있었다. 로스터리 안내를 덧붙이는 문장 안이었고, 추천된 원두 5 개의 정리에는 영향이 없었다.

## 4. 논의

### 4.1 해석

사전에 정한 기준으로 보면 세 쌍(A-B, A-C, B-C)이 모두 "비슷하다"였으므로, 이 실험에서 가설은 지지되었다. 문장이 다른 응답끼리의 평균 겹침(3.85~4.02 개)은 같은 문장을 반복했을 때를 기준으로 맞춘 기준선(3.96~4.16 개)보다 0.14 개 이내로 낮았을 뿐이다. 같은 문장을 반복해도 매번 같지 않은 정도의 흔들림이 있었고, 문장을 바꿔서 생긴 변화는 그 흔들림보다 뚜렷하게 크지 않았다.

**작성자의 판단.** 취향을 이미 알고 있어서 5 가지 요소를 담아 말한다면, 표현 방식이 달라도 AI 의 원두 추천은 거의 비슷하게 나온다고 본다. 예상(가설)대로 흘러갔지만, 질문 자체에 선호하는 취향을 자세하게 썼기 때문에 변화가 너무 없었던 것은 아닌가 하는 아쉬움이 있다. 또 다른 사람들은 자신의 취향을 이렇게 말하기가 어려울 것이라고 생각하는데, 그런 경우는 이번 실험에서 확인하지 않았다.

### 4.2 결과가 이렇게 나온 이유로 검토한 가능성

1. **세 문장이 같은 취향 5 요소를 모두 담고 있었다.** 표현만 달랐을 뿐 AI 가 받은 정보의 양은 같아서 차이가 날 여지가 작았을 수 있다. 취향 요소를 일부만 말하는 문장은 이번에 시험하지 않았다. 이 가능성은 이번 데이터만으로는 확인할 수 없다.

2. **AI 가 이 취향에 대해 정해진 소수의 원두를 반복해서 내놓았을 수 있다.** 예가체프와 케냐는 30 개 응답 모두에, 파나마 게이샤는 28 개 응답에 들어 있었다(표 11). 이 경우 기준선 자체가 4 개 안팎으로 높아서 "달라졌다"가 나오기 어려웠을 수 있다. 이 점은 표 11 의 값으로 확인했다.
3. **같은 원두 판단 규칙이 겹침을 크게 계산했을 수 있다.** 주 규칙은 한쪽에 적히지 않은 칸을 건너뛰므로 덜 구체적으로 적힌 원두가 같다고 판정되기 쉽다. 이 가능성을 확인하려고 이름이 완전히 같을 때만 같다고 보는 보조 규칙을 함께 계산했고(표 10), 세 쌍 모두 같은 결론("비슷하다")이었다.
4. **세 문장이 모두 맛 표현에 능숙한 사람의 문장에 가까웠다.** 특징을 정확한 단어로 말했기 때문에 표현 방식이 달라도 AI 가 같은 특징을 읽어냈을 수 있다. 이 가능성은 이번 데이터만으로는 확인할 수 없다.

## 4.3 가설을 고쳤는가

가설은 고치지 않았다. 처음 가설과 최종 가설이 같다. 데이터 수집 전에 AI 의 초안(표현이 달라질수록 겹침이 줄어든다)을 작성자의 예상에 맞춰 반대 방향으로 바꾼 것이 가설을 다듬은 유일한 변경이며, 그 과정은 1.4 에 적었다.

## 4.4 결론

같은 커피 취향을 구체적 서술, 짧은 키워드, 비유적 표현으로 다르게 말해 Claude Sonnet 5.5 에 원두를 추천받았을 때, 추천된 5 개 중 같은 원두의 개수는 문장이 다른 응답끼리 평균 3.85~4.02 개로, 같은 문장을 반복했을 때를 기준으로 맞춘 기준선 3.96~4.16 개보다 0.14 개 이내로 낮았다. 미리 정한 기준(0.5 개 이상 낮으면 "달라졌다")에 비해 차이가 매우 작았으므로, 이 실험에서는 표현이 달라진 것만으로는 추천된 원두 목록이 크게 달라지지 않았다. 따라서 가설은 지지되었다. 이 결론은 취향의 5 가지 요소를 모두 담은 문장 3 종, 한 모델(Claude Sonnet 5.5), 한 가지 취향, 30 회 요청이라는 조건 안에서만 말할 수 있다.

## 4.5 한계와 앞으로 확인할 것

- 한 가지 취향(강한 산미, 꽃향, 시트러스 계열 과일향, 긴 여운, 약한 쓴맛), 한 모델과 한 설정, 한 계정, 문장 3 종만 사용했다. 다른 취향이나 다른 모델에서도 같은 결과가 나온다고 말할 수 없다.
- 세 문장이 모두 같은 취향 5 요소를 담고 있어서 차이가 날 여지가 작았을 수 있다. 취향 요소를 일부만 말하는 문장이나 취향을 말로 표현하기 어려운 사람의 경우는 확인하지 못했다. 이것이 앞으로 확인할 첫 번째 것이다.
- 세 문장은 모두 커피 맛을 표현하는 데 익숙한 사람이 쓴 문장에 가깝다고 작성자는 판단한다. 맛을 말로 표현하는 데 서툰 사람이 쓰는 문장은 시험하지 않았으므로, 이 결과가 보통 사용자의 말투에도 그대로 적용되는지는 말할 수 없다.
- 응답 쌍은 서로 독립이 아니다(같은 응답이 여러 쌍에 쓰인다). 그래서 통계 검정은 하지 않았고, 사전에 정한 0.5 개 기준으로만 판단했다. 같은 문장 10 회 반복은 표본이 작아서, 겹침이 흔들리는 폭을 정밀하게 말하지 못한다.
- 같은 원두 판단 규칙을 30 회 수집이 끝난 뒤, 겹침을 계산하기 전에 확정했다. 보조 규칙으로 결론이 같은지 확인했지만 규칙을 수집 전에 정하지 못한 점은 한계다.
- 규칙의 한계: 괄호 안에 품종이 적힌 3 개 항목(요청 13, 22, 27)은 품종으로 기록되어 같은 나라의 평범한 항목과 다른 원두로 판정된다. 한 항목에 두 나라나 두 품종이 묶인 경우는 하나라도 겹치면 같다고 보기 때문에 덜 구체적일수록 같다고 판정되기 쉽다. 요청 5-5, 13-2, 19-2, 27-2 는 판단이 갈리는 항목이어서 기록자가 정한 대로 적었다.
- 150 개 원두를 네 칸으로 정리하는 일은 AI 가 했고, AI 가 스크립트와 눈으로 원문과 대조했다. 작성자가 150 줄을 전부 다시 확인하지는 않았다.

- 프롬프트 외의 조건을 완전히 통제하지는 못했다. 비공개 대화에서도 프로필 설정은 쓰일 수 있고(고객센터 안내), 실제로 "대구"라는 지역 언급이 3 개 응답(요청 13, 15, 20)에 나왔다. 웹 검색은 끌 수 없었고 30 회 모두 웹 검색 표시는 보이지 않았다.
- 요청 1~3 은 10 월 30 일, 나머지는 11 월 1 일에 보냈고, 요청 28 과 29 사이에 약 30 분의 간격이 있었다. 날짜나 시간대에 따른 영향은 따로 보지 않았다.

## 참고문헌

표기 형식: 저자 (연도). 제목. 출처, 식별자. URL

[1] Sclar, M., Choi, Y., Tsvetkov, Y., & Suhr, A. (2023). Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting. arXiv preprint, arXiv:2310.11324. https://arxiv.org/abs/2310.11324

[2] Khirbat, M., Castells, P., Ren, Y., & Sanderson, M. (2024). Metamorphic Evaluation of ChatGPT as a Recommender System. arXiv preprint, arXiv:2411.12121. https://arxiv.org/abs/2411.12121

[3] Ouyang, S., Zhang, J. M., Harman, M., & Wang, M. (2023). An Empirical Study of the Non-determinism of ChatGPT in Code Generation. arXiv preprint, arXiv:2308.02828. https://arxiv.org/abs/2308.02828

[4] Atil, B., Aykent, S., Chittams, A., Fu, L., Passonneau, R. J., Radcliffe, E., Rajagopal, G. R., Sloan, A., Tudrej, T., Ture, F., Wu, Z., Xu, L., & Baldwin, B. (2025). Non-Determinism of "Deterministic" LLM Settings. arXiv preprint, arXiv:2408.04667 (v5). https://arxiv.org/abs/2408.04667

연도 표기: [2]는 작성자가 arXiv 페이지에서 직접 확인한 제출일(arXiv:2411.12121v1, 2024 년 11 월 18 일)을 기준으로 2024 로 적었다.

이 논문에서 쓴 도구 설명서: Claude 고객센터, "Use incognito chats". 비공개 대화에서 기억 기능이 쓰이지 않고 프로필 설정은 쓰일 수 있다는 설명을 확인한 출처다.

## 재현 방법

제출한 ZIP 안의 폴더 구성은 다음과 같다.

| 위치 | 내용 |
|---|---|
| 논문.docx | 이 논문 |
| README.md | 재현 방법 요약과 "재현·통과 확인 4 가지" |
| raw/ (30 개 파일) | 원자료. 요청마다 보낸 문장과 응답 원문 전체 (01_A.txt ~ 30_C.txt) |
| screenshots/ (30 개 파일) | 원자료 보충. 요청마다 화면 캡처 |
| data.csv | 원자료를 원두 단위(150 줄)로 정리한 표 |
| scripts/build_data.py | raw/의 응답에서 data.csv 를 만들고, 정리한 값이 응답 제목 줄에 실제로 있는지 검사한다 |
| scripts/analyze.py | 겹침을 세고 기준에 따라 판정한다 (주 규칙, 보조 규칙) |
| scripts/make_figures.py | 그림 1 과 추천 빈도표를 만든다 (matplotlib 필요) |
| results/ | 계산 결과(summary.csv, freq.csv, fig1_overlap.png) |

| 위치 | 내용 |
|---|---|
| pilot/ | 시험 실행 2 회의 원자료. 본 데이터 30 건에 포함하지 않음 |
| 문서/ | 1~3 단계 문서(가설, 논거, 설계와 변경 기록) |

다른 폴더에 ZIP 을 풀고 터미널에서 풀린 폴더 안으로 이동한 뒤(Python 3 필요) 아래 두 줄을 실행하면 결과를 다시 확인할 수 있다.

```
python3 -I scripts/build_data.py
python3 -I scripts/analyze.py
```

첫 줄을 실행하면 "요청 수 30 문장별 {'A': 10, 'B': 10, 'C': 10} / 줄 수 150 / 원문 파일 수 30"과 "검사에서 걸린 것: 0"이 보이고, 둘째 줄을 실행하면 표 8 과 표 10 의 값(주 규칙 A-B 3.96, A-C 4.02, B-C 3.85, 모두 "비슷하다")이 보인다. 자세한 확인 방법은 README.md 에 있다.

## AI 와 나의 판단

| 구분 | 내용 |
|---|---|
| AI 에게 맡긴 일 | 후보 질문 10 개 뽑기, 선행 연구 후보 검색, 설계안과 판정 규칙 초안, 응답을 네 칸(생산국, 세부 지역, 품종, 가공 방식)으로 정리하는 표 작성과 원문 대조, 겹침 계산과 표·그림 만들기, 논문 문장 초안 |
| 내가 판단한 일 | 관심 분야와 최종 주제 선택, 가설의 방향("비슷할 것"), 커피 취향 5 요소와 문장 C 수정, 같은 원두의 기준(나라, 지역, 가공 방식)과 빈칸·여러 값 처리 방식, "달라졌다"의 기준 0.5 개, 참고문헌 직접 확인과 불확실한 문헌 제외, 요청 30 회 전부 직접 보내기, 결과 해석과 결론 |
| AI 말을 안 들은 일 | AI 의 가설 초안("표현이 달라질수록 겹침이 줄어든다")을 따르지 않고 "비슷할 것"으로 방향을 바꿨고, 같은 원두를 이름 수준으로만 보자는 AI 의 절충안을 거절해 나라·지역·가공 방식 기준을 유지했다 |

*표 12. AI 와 나의 판단 3 줄*